

Mapas Auto-Organizáveis: Descoberta de Padrões e Redução de Dimensionalidade

Redes Neurais Artificiais

André Tomonaga Schettini Vitor da Costa Garcia

Universidade Estadual de Londrina (UEL)

25 de novembro

1 1. Como o Mapa Auto-Organizável Funciona? (Q13)

- Visão Geral
- Ciclo de Aprendizado
- Classificação como Rede Neural
- Demonstração Interativa

2 2. Padrões sem Rótulos (Q10)

- Descoberta de Estruturas

3 3. Redução de Dimensionalidade (Q15)

- Preservação da Informação
- Conclusão

Como um Mapa Auto-Organizável organiza informações?

O ****Mapa Auto-Organizável**** mapeia dados de alta dimensão em uma grade regular e contínua de baixa dimensão (geralmente bidimensional).

Estrutura Básica

- Camada de entrada contínua (D dimensões).
- Grade discreta de neurônios (ex: retangular ou hexagonal).
- Cada neurônio j possui um vetor sináptico de pesos $\mathbf{w}_j \in \mathbb{R}^D$.

Princípio de Auto-Organização

Neurônios vizinhos na grade aprendem a responder a padrões de entrada semelhantes no espaço original, sem necessidade de supervisão externa.

Os Três Passos do Mapa Auto-Organizável

A dinâmica de treinamento baseia-se em três etapas competitivas e cooperativas:

- 1 **Competição (Neurônio Vencedor):** Para um dado vetor de entrada $\mathbf{x}$, determina-se a unidade de melhor correspondência (menor distância euclidiana):

$$i(\mathbf{x}) = \arg \min_j \|\mathbf{x} - \mathbf{w}_j\|$$

- 2 **Cooperação (Vizinhança Topológica):** O neurônio vencedor excita seus vizinhos na grade por meio de uma função de vizinhança Gaussiana $h_{j,i(\mathbf{x})}$.
- 3 **Adaptação (Ajuste de Pesos):** Os pesos do vencedor e de sua vizinhança aproximam-se do ponto $\mathbf{x}$:

$$\mathbf{w}_j(t+1) = \mathbf{w}_j(t) + \eta(t)h_{j,i(\mathbf{x})}(t)(\mathbf{x} - \mathbf{w}_j(t))$$

Fuga do MLP: Por que ainda é uma Rede Neural?

Ao contrário do Perceptron e das redes Multicamadas (MLP), o Mapa Auto-Organizável **não utiliza retropropagação de erro (backpropagation), funções de ativação sigmóides nem gradiente descendente supervisionado**.


Ainda assim, é legitimamente uma Rede Neural Artificial:

Paralelismo e Pesos Sinápticos

- Composto por unidades fundamentais de processamento (**neurônios**).
- O conhecimento fica armazenado na magnitude dos **pesos sinápticos** conectando as entradas às unidades da grade.

Inspiração Biológica Real

- Modela a **plasticidade cerebral** do córtex sensorial (mapas tonotópicos e somatossensoriais).
- Fundamenta-se no princípio do **aprendizado hebbiano** e na inibição lateral cortical.



<https://som.161.153.81.139.sslip.io>

Demonstração em Tempo Real

- Aponte a câmera do celular para o QR Code para abrir o simulador interativo.
- Observe a grade do mapa se dobrando e ocupando as regiões densas do espaço de dados.
- Acompanhe a transição da ordenação global até a convergência local refinada.

Como descobrir padrões sem rótulos?

Sem rótulos de classe ou supervisão externa, a descoberta de padrões fundamenta-se unicamente nas ****regularidades intrínsecas**** do conjunto de dados:

- **Geometria e Proximidade:** Amostras com características comuns agrupam-se naturalmente sob neurônios vizinhos no mapa.
- **Densidade de Probabilidade:** O mapa aproxima a distribuição contínua dos dados — regiões mais densas ativam e moldam mais neurônios.
- **Visualização com Matriz-U:** Mede as distâncias euclidianas entre os pesos de neurônios vizinhos. Vales representam agrupamentos homogêneos e cumes indicam as fronteiras de separação.

Conexão com o Aprendizado Não Supervisionado

A rede não precisa de respostas prévias; ela organiza a informação mapeando correlações estatísticas entre as variáveis de entrada.

Como reduzir a dimensionalidade preservando informação?

Reduzir dimensões ($D \rightarrow 2$ ou 3) exige projetar os dados mantendo a sua geometria fundamental:

Preservação Topológica

- Se dois pontos estão próximos no espaço original $\mathbb{R}^D$, seus respectivos neurônios vencedores estarão próximos na grade 2D.
- Capacidade de desdobramento não-linear de variedades (*manifold unrolling*).

Vantagens da Projeção

- Compressão mantendo a estrutura global de vizinhança.
- Facilita a inspeção visual humana de distribuições complexas em alta dimensão.

Síntese e Considerações Finais

- O ****Mapa Auto-Organizável**** organiza informações por competição, cooperação espacial e atualização sináptica adaptativa (Q13).
- É uma rede neural legítima ancorada na neurobiologia cortical e no aprendizado hebbiano, operando sem retropropagação.
- Identifica ****agrupamentos e padrões latentes**** sem necessidade de rótulos prévios (Q10).
- Executa uma ****redução de dimensionalidade não-linear**** com preservação estrita da topologia dos dados (Q15).

Obrigado pela atenção!

Dúvidas ou Comentários?