

Mapas Auto-Organizáveis: Descoberta de Padrões e Redução de Dimensionalidade

Redes Neurais Artificiais

André Tomonaga Schettini Vitor da Costa Garcia

Universidade Estadual de Londrina (UEL)

25 de novembro

Roteiro da Apresentação

1 1. Como o Mapa Auto-Organizável Funciona? (Q13)

- A Intuição
- A Estrutura Matemática
- O Algoritmo: Passo a Passo
- O Algoritmo: Passo a Passo
- Pseudocódigo
- Classificação como Rede Neural
- Exemplo e Demonstração

2 2. Padrões sem Rótulos (Q10)

- Descoberta de Estruturas

3 3. Redução de Dimensionalidade (Q15)

- Preservação da Informação
- Conclusão

A Metáfora do "Lençol de Borracha"

Para entender o SOM, imagine um espaço 3D contendo uma nuvem de pontos (nossos dados) e um **lençol de borracha quadriculado** (nossa rede neural).

O Processo Físico

- Escolhemos um ponto de dado aleatório.
- Agarramos o **nó do lençol** mais próximo desse ponto e o puxamos até ele.
- Como é elástico, ele **arrasta os nós vizinhos** junto com ele.

Resfriamento

No início, o lençol é muito flexível e se move em grandes blocos (ordenação global). Com o tempo, ele enrijece e ajusta apenas detalhes (convergência local).

Ciclo de Treinamento: A Estrutura e Inicialização do Mapa

O SOM conecta dois espaços distintos: a **grade topológica 2D** ($\mathbb{Z}^2$, que define as vizinhanças) e o **espaço de entrada** ($\mathbb{R}^D$, onde residem os dados $\mathbf{x}$ e os pesos $\mathbf{w}_j$).

1. Configuração da Grade

- Define-se o arranjo discreto (ex.: matriz 20×20).
- Cada nó j da grade é um neurônio que terá um vetor de pesos $\mathbf{w}_j \in \mathbb{R}^D$.
- A grade 2D serve como o "tecido elástico" a ser posicionado.

2. Posições Iniciais no Espaço $\mathbb{R}^D$

- **Aleatória:** Valores ao acaso em $\mathbb{R}^D$ (mais lenta, risco de torções topológicas).
- **Amostrai:** Sorteia instâncias reais do próprio dataset para iniciar os nós.

Ciclo de Treinamento: Competição e Cooperação

A cada iteração (ou época), a rede executa etapas baseadas em princípios biológicos:

- 1 Competição (Achar o Vencedor - BMU):** Apresentamos um dado $\mathbf{x}$. O neurônio c com o vetor de pesos mais próximo vence (menor distância euclidiana):

$$c = \arg \min_j \|\mathbf{x} - \mathbf{w}_j\|$$

- 2 Cooperação (Vizinhança):** O vencedor c avisa seus vizinhos na grade 2D que eles também vão aprender. A força do aviso decai com a distância na grade, usando uma Gaussiana:

$$h_{c,j}(t) = \exp \left(-\frac{\|\mathbf{r}_c - \mathbf{r}_j\|^2}{2\sigma^2(t)} \right)$$

Ciclo de Treinamento: Adaptação

- 3 Adaptação (Puxar o lençol):** Os pesos do vencedor e de seus vizinhos são movidos em linha reta na direção do dado $\mathbf{x}$:

$$\mathbf{w}_j(t+1) = \mathbf{w}_j(t) + \eta(t) \cdot h_{c,j}(t) \cdot (\mathbf{x} - \mathbf{w}_j(t))$$

- $\eta(t)$: Taxa de aprendizado (tamanho do passo).
- $(\mathbf{x} - \mathbf{w}_j)$: Vetor direção apontando do neurônio para o dado.

- 4 Decaimento (Resfriamento):** A taxa de aprendizado $\eta(t)$ e o raio de vizinhança $\sigma(t)$ diminuem ao longo do tempo. O mapa passa de uma *ordenação global* grossa para um *ajuste fino* local.

Algoritmo Geral: Ciclo de Treinamento do SOM

Algorithm 1: Treinamento do SOM Clássico

Input: $X \in \mathbb{R}^{n \times p}$, $\epsilon_0, \sigma_0, T_{\max}$, distâncias d e d^*

Output: Grade treinada de pesos $E = \{W_i\}$

```

1 Inicializar a grade  $E$  com pesos aleatórios  $W_i$ ;
2 for  $t \leftarrow 1$  to  $T_{\max}$  do
3     Selecionar  $X^* \in X$  aleatoriamente;
4      $W^* \leftarrow \arg \min_{W \in E} d(W, X^*)$ ;           // Achar o BMU
5     for cada neurônio  $W_i \in E$  do
6          $W_i(t+1) \leftarrow W_i(t) + \Theta(t) \epsilon(t) (X^* - W_i(t))$ ;
7     Atualizar decaimentos:
8          $\Theta(t) = \exp\left(-\frac{d^*(W^*, W_i)}{2\sigma^2(t)}\right)$ ;
9          $\sigma(t) = \sigma_0 \exp(-t/T_{\max})$ ;
10         $\epsilon(t) = \epsilon_0 \exp(-t/T_{\max})$ ;
  
```

Parâmetros-Chave

- **d vs. d^* :** d opera no espaço dos dados ($\mathbb{R}^p$); d^* opera na topologia da grade.
- **X^* :** Amostra estocástica sorteada a cada época/ passo t .
- **W^* :** O neurônio vencedor (BMU).
- **$\Theta(t)$:** Ponderador gaussiano de vizinhança.

Fuga do MLP: Por que ainda é uma Rede Neural?

Ao contrário das redes Multicamadas (MLP), o SOM **não utiliza retropropagação de erro (backpropagation) nem gradiente descendente.**

Ainda assim, é legitimamente uma Rede Neural Artificial:

Paralelismo e Pesos

- O conhecimento é armazenado de forma distribuída na magnitude dos **pesos sinápticos**.

Inspiração Biológica Real

- Modela a **plasticidade do córtex cerebral** (mapas somatossensoriais).
- Baseia-se na *inibição lateral* e no aprendizado Hebbiano.

O Exemplo Clássico: Mapeamento de Cores RGB


Para visualizar a topologia, treinamos um SOM com **cores aleatórias**:

- **Entrada ($D = 3$):** Vetores com canais Vermelho, Verde e Azul $[R, G, B]$.
- **Saída (Grade 2D):** Matriz de 40×40 neurônios.

A Evolução do Treinamento

- 1 **Início:** Uma tela de "estática" ruidosa, cores misturadas.
- 2 **Meio:** Manchas borradas agrupam tons parecidos (verdes puxando verdes).
- 3 **Fim:** Um arco-íris contínuo e suave, provando que o espaço 3D foi achatado em 2D perfeitamente.

Visualização Interativa



<https://som.161.153.81.139.sslip.io>

Demonstração em Tempo Real

- Aponte a câmera para abrir o simulador.
- Observe a grade se dobrando no espaço de dados.
- Acompanhe a transição da ordenação global (movimentos amplos) para a convergência local refinada.

Como descobrir padrões sem rótulos?

Sem rótulos de classe ou supervisão externa, a descoberta de padrões fundamenta-se unicamente nas ****regularidades intrínsecas**** do conjunto de dados:

- **Geometria e Proximidade:** Amostras com características comuns agrupam-se naturalmente sob neurônios vizinhos no mapa.
- **Densidade de Probabilidade:** O mapa aproxima a distribuição contínua dos dados — regiões mais densas ativam e moldam mais neurônios.
- **Visualização com Matriz-U:** Mede as distâncias euclidianas entre os pesos de neurônios vizinhos. Vales representam agrupamentos homogêneos e cumes indicam as fronteiras de separação.

Conexão com o Aprendizado Não Supervisionado

A rede não precisa de respostas prévias; ela organiza a informação mapeando correlações estatísticas entre as variáveis de entrada.

Como reduzir a dimensionalidade preservando informação?

Reduzir dimensões ($D \rightarrow 2$ ou 3) exige projetar os dados mantendo a sua geometria fundamental:

Preservação Topológica

- Se dois pontos estão próximos no espaço original $\mathbb{R}^D$, seus respectivos neurônios vencedores estarão próximos na grade 2D.
- Capacidade de desdobramento não-linear de variedades (*manifold unrolling*).

Vantagens da Projeção

- Compressão mantendo a estrutura global de vizinhança.
- Facilita a inspeção visual humana de distribuições complexas em alta dimensão.

Síntese e Considerações Finais

- O ****Mapa Auto-Organizável**** organiza informações por competição, cooperação espacial e atualização sináptica adaptativa (Q13).
- É uma rede neural legítima ancorada na neurobiologia cortical e no aprendizado hebbiano, operando sem retropropagação.
- Identifica ****agrupamentos e padrões latentes**** sem necessidade de rótulos prévios (Q10).
- Executa uma ****redução de dimensionalidade não-linear**** com preservação estrita da topologia dos dados (Q15).

Obrigado pela atenção!

Dúvidas ou Comentários?